

AI 優化器方法比較



AI 訓練在反向傳播後有了梯度, 之後的優化器除了: 梯度下降
還有那些重要的方法?

以下以簡潔、清楚、繁體中文整理：

在反向傳播計算出梯度後, **優化器 (Optimizer)** 負責依據梯度更新權重。除了最基本的 **梯度下降法 (GD / SGD)** 外, 深度學習中還有許多更高效、常用的優化器。

★ 常見且重要的 AI 優化器 (Optimizers)

1 SGD (Stochastic Gradient Descent)

最基礎的方法, 以隨機小批次更新。

✓ 優點：簡單、穩定

✗ 缺點：收斂慢、容易卡在局部最小值

✦ 加強版：

► SGD + Momentum (動量法)

加入「慣性」, 讓更新方向更平滑、不易被雜訊影響。

→ 速度更快、較不容易卡住。

► Nesterov Accelerated Gradient (NAG)

Momentum 的改良版

→ 比 Momentum 更快、預測下一步並提早修正。

2 AdaGrad (Adaptive Gradient)

每個參數都有自己的學習率, 出現頻繁的特徵會降低學習率。

✓ 對稀疏資料 (NLP、One-hot) 效果很好

✗ 在深度網路中學習率過快衰減, 容易停滯。

3 RMSProp

AdaGrad 的改良版, 使用「指數移動平均」避免學習率快速下降。

✓ 目前非常常用

✓ 適合 RNN / LSTM

✓ 比 AdaGrad 更穩定
→ 幾乎取代 AdaGrad。

4 ★ Adam (Adaptive Moment Estimation)

目前深度學習中 最常用的優化器之一。

結合：

- Momentum (動量)
- RMSProp (自動調整學習率)

✓ 收斂快
✓ 對超參數不敏感
✓ 對 CNN、RNN、Transformer 都常用
→ 目前預設/推薦的 baseline optimizer。

5 AdamW (新版的 Adam) — ★ 現在最推薦

解決 Adam 的「正規化問題」，把 weight decay 正確分離。

✓ 目前 transformer / 大模型預訓練 (如 BERT, GPT) 標準用法
✓ 比 Adam 更穩定、更可控

6 Nadam (Nesterov + Adam)

將 Nesterov momentum 加入 Adam。

→ 一般較少使用，但理論上收斂更平滑。

7 Adadelata

AdaGrad 改良版，不需要手動設定學習率。

適用：少量參數的小模型

現今用得較少。

8 L-BFGS (準牛頓法 Quasi-Newton)

✓ 準確、收斂快
✗ 記憶體需求大，不適合大型深度網路
通常用在：

- 小模型
- 傳統機器學習
- 少量資料情境

★ 實務界最常使用的 3 大優化器

優化器	特性	使用情境
Adam	收斂快、穩定	最常用、通用
AdamW	Adam 的最佳版本	Transformer、大模型、現代深度學習
SGD + Momentum	最高準確率（但較慢）	CNN（ResNet 等）、學術研究

📌 總結

反向傳播 → 計算梯度

優化器 → 利用梯度更新權重

最重要的優化器包括：

👉 SGD / SGD+Momentum / NAG

👉 AdaGrad / RMSProp / Adadelta

👉 Adam / AdamW / Nadam

👉 L-BFGS（小模型使用）

如果你要我整理成：

✓ 圖表

✓ 流程圖

✓ PPT

✓ Markdown 課程講義

我也可以幫你製作！